

Informe Integrado del Examen Parcial 2026-I

Tres Problemas de Visión por Computador con Aprendizaje Profundo:
Clasificación de Texturas (CNN) · Segmentación Densa (U-Net) · Detección de Objetos (YOLO)

Equipo 6 — Sección A

Arraiza Nicola, E.

Montoya Juro, N.

Paria Luján, J.

Rosario Valladares, G.

Vidal Chávez, J.

Resumen

El presente trabajo aborda el problema de la detección automática de daños en llantas mediante técnicas de visión por computador y aprendizaje profundo. Se desarrolló un sistema de clasificación binaria capaz de distinguir entre llantas en buen estado y llantas con grietas o deformaciones visibles a partir de imágenes de textura superficial. Para ello, se compararon dos enfoques: una red neuronal convolucional (CNN) diseñada desde cero y un modelo basado en transferencia de aprendizaje utilizando ResNet-50 preentrenada en ImageNet.

El conjunto de datos empleado estuvo compuesto por imágenes de llantas clasificadas en las categorías *normal* y *cracked*, aplicándose técnicas de preprocesamiento, aumento de datos y validación estratificada. La evaluación se realizó mediante métricas apropiadas para problemas con desbalance de clases, incluyendo exactitud, precisión, recall, F1-score y AUC-ROC.

Los resultados evidenciaron una diferencia significativa entre ambos enfoques. Mientras que la CNN entrenada desde cero presentó dificultades para generalizar debido al tamaño limitado del conjunto de datos, el modelo ResNet-50 alcanzó un desempeño superior, obteniendo un AUC-ROC de 0.900 y un F1-score de 0.760 sobre la clase de interés. Asimismo, se realizó un estudio de ablación para analizar el impacto del aumento de datos y de distintas funciones de pérdida, así como una evaluación del efecto del desbalance de clases mediante ponderación de muestras.

Finalmente, se empleó la técnica Grad-CAM para interpretar las decisiones del modelo, verificando que las regiones de mayor activación correspondían efectivamente a grietas y deformaciones presentes en las llantas. Los resultados demuestran que la transferencia de aprendizaje constituye una estrategia eficaz para la inspección automatizada de neumáticos, ofreciendo una solución objetiva y escalable para aplicaciones de seguridad vial y mantenimiento preventivo.

Parte I — Clasificación de Llantas Dañadas mediante Reconocimiento de Textura (CNN)

1. Motivación y Relevancia del Problema

El estado de las llantas es un factor crítico para la seguridad vial: el desgaste, las grietas y las deformaciones del caucho incrementan de forma significativa el riesgo de reventones y de pérdida de adherencia. La inspección tradicional es subjetiva, depende de las condiciones de observación y no escala a flotas de vehículos ni a entornos industriales con miles de unidades. La visión por computador ofrece una alternativa objetiva, consistente y automatizable.

El objetivo de esta parte es construir un clasificador binario que distinga entre llantas en buen estado (normal) y llantas con daños visibles (cracked) a partir de imágenes de la textura superficial. Más allá de maximizar la exactitud, el trabajo enfatiza tres aspectos que condicionan el despliegue real: el efecto del desbalance de clases sobre la detección de la clase crítica, la interpretabilidad de las decisiones del modelo mediante Grad-CAM, y un análisis honesto de los modos de fallo.

2. Trabajos Relacionados

He et al. (2016) introdujeron las redes residuales (ResNet), cuyas conexiones de salto permiten entrenar redes muy profundas sin desvanecimiento del gradiente; ResNet-50 preentrenada en ImageNet se ha consolidado como backbone de referencia para transferencia de aprendizaje en visión industrial. Tan y Le (2019) propusieron EfficientNet, que escala profundidad, anchura y resolución de forma conjunta para lograr mejor rendimiento con menos parámetros.

Bergmann et al. (2019) publicaron MVTec AD, un referente para detección de anomalías en texturas industriales, mostrando que los modelos preentrenados superan a los entrenados desde cero cuando el conjunto objetivo tiene menos de unos pocos miles de imágenes — precisamente el régimen del presente trabajo. Cha et al. (2017) aplicaron CNN a la detección de grietas en hormigón, un problema estructuralmente análogo (textura, desbalance, necesidad de interpretabilidad), y reportaron que el aumento de datos agresivo es necesario para generalizar.

Selvaraju et al. (2017) propusieron Grad-CAM, técnica de interpretabilidad aplicable a cualquier CNN que localiza, mediante los gradientes de la última capa convolucional, las regiones más influyentes en la decisión. Para el manejo del desbalance, Lin et al. (2017) introdujeron la Focal Loss, que modula la entropía cruzada para concentrar el aprendizaje en los ejemplos difíciles, y Chawla et al. (2002) propusieron SMOTE, cuya filosofía de sobremuestreo de la clase minoritaria se traslada al aumento de datos en imágenes. El conjunto de datos empleado fue publicado por Bhathena (2020) en Kaggle.

3. Conjunto de Datos y Análisis Exploratorio

El conjunto Tire Texture Image Recognition contiene imágenes RGB de la superficie de llantas en dos clases: normal (rodadura intacta) y cracked (grietas, cortes o deformaciones). Se respetó la partición preexistente: el directorio de entrenamiento se dividió de forma estratificada en entrenamiento (596 imágenes) y validación (107 imágenes), y el directorio de prueba se reservó íntegro como conjunto de test final (325 imágenes: 115 normal y 210 cracked), evaluado una

sola vez. La distribución del conjunto de trabajo presenta una ligera mayoría de la clase cracked (razón cracked/normal ≈ 1.09), mientras que en el conjunto de test la clase cracked es claramente mayoritaria, lo que vuelve engañosa cualquier métrica de exactitud global.




Figura 1. Distribución de clases en el conjunto de datos. El desbalance es moderado pero suficiente para sesgar las métricas agregadas hacia la clase mayoritaria.

El análisis exploratorio muestra una fuerte heterogeneidad en dimensiones (desde $\sim 200 \times 200$ hasta $\sim 1000 \times 1000$ píxeles) y en condiciones de iluminación y encuadre. Todas las imágenes se redimensionaron a 224×224 píxeles, resolución estándar para ResNet-50. Las llantas normal exhiben relieves regulares y repetitivos del dibujo de rodadura; las cracked presentan grietas longitudinales o transversales, cortes profundos y pérdida parcial del dibujo.



Figura 2. Muestras de la clase normal: textura de rodadura regular y predecible.



Figura 3. Muestras de la clase cracked: grietas, cortes y deformaciones visibles. La heterogeneidad de iluminación y encuadre justifica el aumento de datos.

4. Metodología

4.1 Preprocesamiento y aumento de datos

Los pipelines de datos se construyeron con `tf.data.Dataset`, aplicando `cache()` y `prefetch(AUTOTUNE)` para solapar la carga de imágenes con el cómputo de la GPU. Se incorporó una capa de aumento de datos integrada en el modelo (activa solo en entrenamiento): volteo horizontal aleatorio, rotaciones de hasta $\pm 10\%$, zoom de $\pm 10\%$ y variaciones de contraste y brillo de $\pm 10\%$. Estas transformaciones simulan distintas orientaciones, escalas y condiciones fotográficas, actuando como regularizador implícito.




Figura 4. Efecto del aumento de datos sobre una imagen de entrenamiento: el modelo observa variaciones geométricas y fotométricas de la misma llanta.

4.2 Modelo A — CNN diseñada desde cero

La primera arquitectura es una CNN con cuatro bloques convolucionales de 32, 64, 128 y 256 filtros. Cada bloque aplica dos convoluciones 3×3 con normalización por lotes y ReLU, seguidas

de max-pooling 2x2. Tras los bloques, un GlobalAveragePooling2D reduce las dimensiones espaciales a un vector de características (con menos parámetros y mayor resistencia al sobreajuste que un Flatten), y la cabeza clasificadora aplica Dropout(0.4) → Dense(128, ReLU) → Dropout(0.3) → Dense(1, sigmoide). El modelo (~1.6 M de parámetros) se entrenó con Adam (lr=1e-3), pérdida BinaryCrossentropy, early stopping sobre val_auc y reducción de la tasa de aprendizaje en mesetas.

4.3 Modelo B — Transferencia de aprendizaje con ResNet-50

La segunda arquitectura emplea ResNet-50 preentrenada en ImageNet (~25 M de parámetros) como extractor de características, con la misma cabeza clasificadora. El entrenamiento se realizó en dos etapas. En la Etapa 1 (feature extraction) el backbone se congeló por completo y solo se entrenó la cabeza (lr=1e-3). En la Etapa 2 (fine-tuning) se descongelaron las últimas ~50 capas (bloque conv5, de mayor abstracción semántica) y se reentrenó con una tasa muy baja (lr=1e-5) para ajustar los filtros de alto nivel a la textura de llantas sin destruir el conocimiento de ImageNet. El preprocesamiento de entrada utilizó la normalización propia de ResNet.

5. Evaluación Comparativa de los Modelos

Para un problema binario con desbalance se reportan exactitud, precisión, recall, F1-score y AUC-ROC sobre el conjunto de test. La curva ROC y la curva Precision-Recall complementan el análisis al ser independientes del umbral de decisión. Los resultados reales obtenidos se resumen en la Tabla siguiente.

Tabla 1. Resultados sobre el conjunto de test (325 imágenes). Métricas de la clase positiva cracked.

Modelo	Accuracy	Precision	Recall	F1-score	AUC-ROC
CNN desde cero	0.354	0.000	0.000	0.000	0.642
ResNet-50 (TL)	0.742	0.950	0.633	0.760	0.900

Hallazgo central. La CNN entrenada desde cero no logró converger a un clasificador útil: con el umbral estándar de 0.5 colapsó prediciendo siempre la clase normal, obteniendo recall y F1 nulos sobre cracked. Su AUC-ROC de 0.642 indica que la red sí capturó cierta capacidad de ordenamiento, pero insuficiente y mal calibrada, consecuencia del tamaño reducido del conjunto frente a la capacidad del modelo. En contraste, ResNet-50 con fine-tuning alcanzó AUC-ROC de 0.900 y F1 de 0.760 sobre la clase crítica, validando empíricamente que las representaciones preentrenadas en ImageNet son transferibles y decisivas en el régimen de pocos datos.




Figura 5. Curvas de entrenamiento de la CNN desde cero. La pérdida de validación se desacopla del entrenamiento y el AUC de validación se estanca, evidenciando sobreajuste e inestabilidad.




Figura 6. Curvas de la etapa de fine-tuning de ResNet-50. El AUC de validación se mantiene alto y estable, reflejando un entrenamiento sano.

5.1 Matrices de confusión

Las matrices de confusión revelan con claridad la diferencia de comportamiento. La CNN desde cero clasifica las 325 imágenes como normal (115 verdaderos negativos, 0 verdaderos positivos), de modo que las 210 llantas dañadas quedan sin detectar. ResNet-50 detecta correctamente 133 de las 210 llantas dañadas y 108 de las 115 sanas; sus 77 falsos negativos constituyen el punto débil operativo, pues representan llantas peligrosas clasificadas como sanas.




Figura 7. Matrices de confusión en test. Izquierda: la CNN desde cero colapsa hacia la clase normal. Derecha: ResNet-50 logra una separación sustancial, con falsos negativos como principal limitación.

La asimetría de costes del dominio (un falso negativo —llanta dañada no detectada— es mucho más grave que un falso positivo —inspección innecesaria—) justifica priorizar el recall sobre cracked. En producción, el umbral de decisión debería desplazarse por debajo de 0.5 para incrementar la sensibilidad, aceptando un mayor número de falsos positivos.

5.2 Curvas ROC y Precision-Recall

La curva ROC confirma la superioridad de ResNet-50 (AUC=0.900) frente a la CNN desde cero (AUC=0.642). La curva Precision-Recall, más informativa bajo desbalance, muestra que ResNet-50 mantiene precisión por encima de 0.9 hasta recalls intermedios, mientras que la CNN se degrada rápidamente. Es notable que la CNN, pese a su colapso en el umbral 0.5, posea una

curva por encima de la diagonal: el problema no es la ausencia total de señal sino la incapacidad de fijar un umbral operativo estable.




Figura 8. Curvas ROC (izquierda) y Precision-Recall (derecha). ResNet-50 domina en todo el rango operativo.

6. Estudio de Ablación

El estudio de ablación aísla la contribución de dos factores sobre la CNN desde cero, manteniendo constantes los demás: el aumento de datos y la función de pérdida (BinaryCrossentropy frente a Focal Loss). Cada configuración se entrenó el mismo número de épocas para garantizar comparabilidad y se evaluó sobre validación.

Tabla 2. Estudio de ablación sobre validación (CNN desde cero). El AUC es la métrica más estable bajo el colapso de umbral.

Configuración	AUC	F1	Precision	Recall
Sin aumento + BCE	0.677	0.373	0.560	0.280
Con aumento + BCE	0.693	0.039	1.000	0.020
Con aumento + Focal	0.585	0.000	0.000	0.000
Sin aumento + Focal	0.772	0.000	0.000	0.000




Figura 9. Estudio de ablación: efecto del aumento de datos y de la función de pérdida sobre la CNN desde cero.

Interpretación. En términos de AUC, el aumento de datos mejora el ordenamiento respecto a su ausencia con la misma pérdida (BCE: 0.677 → 0.693). Sin embargo, ninguna configuración de

la CNN desde cero alcanza un F1 operativo, lo que refuerza el hallazgo principal: el cuello de botella no es la elección de pérdida o de aumento, sino la insuficiencia de una arquitectura entrenada desde cero para este volumen de datos. La transferencia de aprendizaje —y no un ajuste fino de hiperparámetros sobre la red pequeña— es la palanca decisiva.

7. Análisis del Desbalance de Clases y Estrategia de Mitigación

Como estrategia de mitigación se reentrenó la CNN desde cero aplicando pesos de clase balanceados (`class_weight`), que penalizan cada error sobre la clase minoritaria proporcionalmente a su escasez. El objetivo era recuperar recall sobre cracked sin duplicar imágenes físicamente.

Tabla 3. Efecto de los pesos de clase sobre la CNN desde cero.

Modelo	Accuracy	F1 (cracked)	AUC-ROC
CNN desde cero (sin balanceo)	0.354	0.000	0.642
CNN desde cero (<code>class_weight</code>)	0.354	0.000	0.428




Figura 10. Matrices de confusión: CNN desde cero sin balanceo (izquierda) y con pesos de clase (derecha). La estrategia no rescata a un modelo que no aprendió representaciones discriminativas estables.

Lección metodológica. En este caso la ponderación de clases no fue suficiente para revertir el colapso, porque la causa raíz es la falta de capacidad de representación de la red entrenada desde cero, no únicamente el sesgo de frecuencia. Esto confirma que la exactitud global es una métrica insuficiente bajo desbalance con costes asimétricos —un clasificador trivial que predijera siempre la clase mayoritaria del test obtendría 64.6% de exactitud con recall nulo sobre la clase peligrosa— y que el F1 y el recall de la clase minoritaria son las métricas apropiadas para este dominio. La mitigación efectiva del desbalance debe combinarse con una arquitectura suficientemente capaz, como ResNet-50.

8. Interpretabilidad mediante Grad-CAM

Grad-CAM se aplicó sobre la última capa convolucional de ResNet-50 (`conv5_block3_out`) para visualizar qué regiones activan la decisión cracked. El mapa de calor resultante se superpone sobre la imagen original (rojo = alta activación, azul = baja).

Grad-CAM — ResNet-50: regiones que activan la decisión "cracked"




Figura 11. Mapas Grad-CAM de ResNet-50. Fila superior: llantas normal con baja probabilidad de daño. Fila inferior: llantas cracked con $p(\text{cracked})=0.99\text{--}1.00$; las activaciones se concentran sobre grietas, cortes y deformaciones reales.

La validación cualitativa es satisfactoria: en las llantas dañadas las activaciones se concentran sobre las grietas longitudinales, los cortes y las zonas de deformación, y no sobre el fondo o los reflejos. En las llantas sanas las activaciones son difusas y de baja intensidad, coherente con la naturaleza de la normalidad (ausencia de patrones de daño). Grad-CAM confirma así que el modelo aprende representaciones semánticamente correctas y no atajos espurios, requisito indispensable para confiar en él en producción.

9. Análisis Cualitativo de Fallos

Se examinaron los seis errores más severos de ResNet-50 (mayor discrepancia entre probabilidad predicha y etiqueta real). De forma reveladora, los seis son falsos negativos: llantas etiquetadas como cracked que el modelo clasifica como normal con probabilidades de daño muy bajas ($p(\text{cracked})$ entre 0.001 y 0.023).

Top-6 errores más severos del modelo ResNet-50



Figura 12. Los seis errores más severos de ResNet-50. Todos son falsos negativos (real: cracked, predicho: normal), el tipo de error más peligroso en seguridad vial.

Las hipótesis sobre sus causas, derivadas de la inspección visual, son: (i) ambigüedad de etiquetado —daños muy leves o microfisuras en el límite perceptual humano—; (ii) presencia de inscripciones y códigos en relieve que dominan visualmente la imagen y enmascaran la grieta; (iii) condiciones de iluminación que difuminan las fisuras; y (iv) tipos de daño poco representados en el entrenamiento. La concentración de errores en la clase peligrosa, junto con el recall de 0.633, indica que la principal mejora futura es aumentar la sensibilidad: ampliar el conjunto con daños diversos, ajustar el umbral hacia mayor recall e integrar verificación humana para predicciones de baja confianza.

10. Conclusiones de la Parte

- **Transferencia de aprendizaje.** ResNet-50 con fine-tuning superó de forma contundente a la CNN desde cero en todas las métricas (AUC 0.900 vs. 0.642; F1 0.760 vs. 0.000), confirmando el valor de las representaciones de ImageNet en el régimen de pocos datos.
- **Desbalance y costes asimétricos.** La exactitud global es engañosa; el recall y el F1 de la clase cracked son las métricas relevantes. La ponderación de clases por sí sola no rescató a la red pequeña, evidenciando que la mitigación del desbalance requiere además una arquitectura capaz.
- **Interpretabilidad.** Grad-CAM verificó que ResNet-50 atiende a grietas y deformaciones reales, no a artefactos del fondo, lo que respalda su fiabilidad.
- **Modos de fallo.** Los errores más graves son falsos negativos asociados a daños sutiles, inscripciones y condiciones de iluminación. La prioridad de mejora es elevar la sensibilidad mediante datos más diversos, ajuste de umbral y supervisión humana asistida.

11. Referencias

- [1] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep Residual Learning for Image Recognition. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 770–778.
- [2] Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. In Proceedings of the 36th International Conference on Machine Learning (ICML), pp. 6105–6114.
- [3] Bergmann, P., Fauser, M., Sattlegger, D., & Steger, C. (2019). MVTec AD — A Comprehensive Real-World Dataset for Unsupervised Anomaly Detection. In Proceedings of CVPR, pp. 9592–9600.
- [4] Cha, Y. J., Choi, W., & Büyüköztürk, O. (2017). Deep Learning-Based Crack Damage Detection Using Convolutional Neural Networks. *Computer-Aided Civil and Infrastructure Engineering*, 32(5), 361–378.
- [5] Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization. In Proceedings of ICCV, pp. 618–626.
- [6] Lin, T. Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal Loss for Dense Object Detection. In Proceedings of ICCV, pp. 2980–2988.
- [7] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16, 321–357.
- [8] Bhathena, J. (2020). Tire Texture Image Recognition. Kaggle Dataset. Disponible en: <https://www.kaggle.com/datasets/jehanbhathena/tire-texture-image-recognition>