

Detección de Cumplimiento de Normas de Seguridad en Obras de Construcción mediante YOLO: Robustez ante Oclusión y un Verificador de Cumplimiento Basado en Reglas

Equipo 6

Curso de Redes Neuronales y Aprendizaje Profundo

{Arraiza Nicola E. · Montoya Juro N. · Paria Lujan J. · Rosario Valladares G. · Vidal Chávez J.}

Resumen

El sector de la construcción concentra una fracción desproporcionada de los accidentes laborales mortales, muchos de ellos asociados al uso incorrecto o ausente de Equipos de Protección Personal (EPP). Entrenamos y evaluamos un detector basado en YOLO para localizar trabajadores y clasificar su estado de cumplimiento de EPP (casco y chaleco) en imágenes y vídeo de obras activas. Partimos de un backbone preentrenado en COCO y reimplementamos los componentes principales de la cabeza de detección, la pérdida compuesta y el módulo de posprocesamiento. Unificamos tres conjuntos de datos públicos (SHWD, Safety Helmet Detection y PPE Detection) bajo una taxonomía común y abordamos los tres retos centrales del problema: oclusión severa, detección de objetos pequeños y fuerte desbalance de clases (los trabajadores no conformes son escasos en grabaciones reales). Sobre el detector construimos un *verificador de cumplimiento basado en reglas* que asocia EPP a cada trabajador y produce una tasa de cumplimiento por fotograma con marcado de las cajas no conformes. El modelo alcanza un mAP@0.5 de 0.905 y un mAP@0.5:0.95 de 0.575; un análisis estratificado revela una caída de 26,0 puntos de mAP@0.5 entre oclusión baja y alta, concentrada en las clases minoritarias. Cerramos con una discusión de las implicaciones éticas del despliegue, centrada en la asimetría de costes entre falsos negativos y falsos positivos, la privacidad de los trabajadores y los sesgos inducidos por la distribución de los datos.

1 Motivación

La construcción es, de forma persistente, una de las actividades económicas más peligrosas. En la Unión Europea más de una quinta parte de los accidentes laborales mortales se produce en este sector, y en Estados Unidos las muertes en obra superaron el millar en el último año con cifras consolidadas. Una proporción relevante de estas lesiones —traumatismos craneoencefálicos, impactos y caídas— es prevenible mediante el uso correcto de Equipos de Protección Personal (EPP): cascos, chalecos de alta visibilidad y, en trabajos en altura, arneses. El cumplimiento de su uso, sin embargo, depende de la supervisión humana, que no escala a obras grandes, con múltiples frentes de trabajo, turnos prolongados y zonas de visibilidad limitada.

La visión por computador ofrece una vía para automatizar esta supervisión a partir del circuito cerrado de televisión ya presente en muchas obras. Los detectores de objetos de una sola etapa de la familia YOLO [3, 7, 10] son particularmente adecuados por su capacidad de operar en tiempo real sobre vídeo. No obstante, trasladar un detector genérico a la verificación de cumplimiento de EPP no es una aplicación directa de detección de objetos: el problema impone tres dificultades acopladas. (i) **Oclusión severa:** los trabajadores aparecen parcialmente ocultos tras maquinaria, andamios, materiales o entre sí. (ii) **Objetos pequeños:** los trabajadores lejanos ocupan pocos píxeles y su EPP es aún menor, lo que estresa la resolución efectiva del detector. (iii) **Desbalance de clases:** en grabaciones reales la inmensa mayoría de los trabajadores cumple la norma, de modo que los

ejemplos no conformes —precisamente los que el sistema debe detectar— son escasos, y un modelo entrenado de forma ingenua tiende a un sesgo hacia la predicción “conforme”.

A estas dificultades técnicas se añade que la detección por sí sola no resuelve la tarea de *cumplimiento*: detectar un casco y detectar a una persona no implica que ese casco corresponda a esa persona ni que lo lleve puesto. Es necesaria una capa de razonamiento que asocie cada elemento de EPP a un trabajador y derive un veredicto de cumplimiento auditable. Las contribuciones de este trabajo son las siguientes:

- Un detector basado en YOLOv8, con backbone preentrenado y cabeza, pérdida y asignación de etiquetas reimplementadas, afinado sobre una unificación de tres conjuntos de datos públicos bajo una taxonomía común, con decisiones de entrenamiento completamente documentadas (Sección 3.4).
- Una evaluación cuantitativa con desglose por clase en mAP@0.5 y mAP@0.5:0.95, y una comparación entre variantes de capacidad y frente a YOLOv9 (Sección 5).
- Un *análisis de robustez ante oclusión* que particiona el conjunto de prueba por nivel de oclusión estimado y cuantifica la degradación por grupo (Sección 5.2).
- Un *verificador de cumplimiento basado en reglas* que produce una tasa de cumplimiento por fotograma, con suavizado temporal para vídeo y una demostración sobre escenas no vistas (Secciones 3.5 y 5.4).
- Una discusión de las implicaciones éticas del despliegue (Sección 6).

2 Trabajos Relacionados

De los sensores a la visión. Los primeros sistemas de monitoreo de EPP recurrían a sensores físicos —RFID o etiquetas embebidas en los cascos—, una solución costosa, intrusiva y propensa a fallos en el campo. El cambio hacia enfoques basados en visión permitió aprovechar la infraestructura de cámaras existente; los métodos clásicos de procesamiento de imagen combinados con clasificadores, sin embargo, sólo funcionaban en escenas con fondos simples y se degradaban ante la complejidad visual de una obra real.

Detectores profundos para EPP. Con el aprendizaje profundo, la detección de EPP se abordó primero con detectores de dos etapas (Faster R-CNN) y de una etapa (SSD), y posteriormente con la familia YOLO, que ofrece el mejor compromiso entre precisión y velocidad para operación en tiempo real. Wang et al. [9] construyen el conjunto CHV y comparan ocho detectores, obteniendo el mejor mAP (86,55 %) con YOLOv5x y la mayor velocidad (52 FPS) con YOLOv5s; reportan además una caída de 7 puntos en la detección de cascos sobre rostros desenfocados, un primer indicio de la fragilidad ante degradación visual. Ferdous y Ahsan [2] proponen una arquitectura *anchor-free* basada en YOLOX que detecta ocho clases e introducen aumentos fotométricos (lluvia, niebla, baja iluminación) para simular condiciones reales de obra. Trabajos más recientes incorporan mecanismos de atención y super-resolución para objetos pequeños y escenas de baja luz, alcanzando mAP@0.5 en torno a 0,92 y mAP@0.5:0.95 cercanos a 0,74 en conjuntos propios.

Conjuntos de datos de referencia. El *Safety Helmet Wearing Dataset* (SHWD) [8] es uno de los más utilizados: contiene 7.581 imágenes con 9.044 objetos positivos (“casco”) y 111.514 cabezas negativas (“sin casco”), lo que lo hace especialmente valioso para entrenar un clasificador de cumplimiento fiable, aunque su desbalance entre positivos y negativos es pronunciado. Otgonbold et al. [6] amplían y completan el etiquetado en el conjunto SHEL5K, con seis clases plenamente anotadas (casco, cabeza, cabeza con casco, persona con casco, persona sin casco y rostro), evidenciando que muchos conjuntos previos están parcialmente etiquetados, una fuente conocida de ruido de entrenamiento.

Tabla 1. Conjuntos de datos utilizados. SHWD aporta los ejemplos negativos explícitos imprescindibles para un clasificador de cumplimiento fiable.

Conjunto	Clases originales	Imágenes	Licencia / Origen
Safety Helmet Detection	helmet, head, person	~5.000	CC BY 4.0 (Roboflow)
PPE Detection	helmet, vest, glove, person	~10.000	Roboflow Universe
SHWD	hat (pos.), person (neg.)	7.581	GitHub (njvisionpower)

Tabla 2. Ontología de mapeo a la taxonomía unificada. “–” indica clase descartada en ese conjunto.

Clase unificada	Safety Helmet Det.	PPE Detection	SHWD
persona	person	person	–
casco	helmet	helmet	hat
cabeza	head	–	person
chaleco	–	vest	–
sin_chaleco	–	(inferida)	–
guante	–	descartada	–

Arquitecturas YOLO. YOLOv8 [3] adopta un diseño *anchor-free* con cabeza desacoplada y asignación de etiquetas alineada a la tarea (*task-aligned assignment*, en la línea de 1), y combina una pérdida de clasificación con una pérdida de regresión de caja basada en *Distribution Focal Loss* y CIOU. Wang et al. [10] introducen la *Programmable Gradient Information* (PGI) y la red *GELAN* para mitigar la pérdida de información a lo largo de la red profunda, mejorando la utilización de parámetros sobre MS COCO [4]. Para el desbalance de clases, la *Focal Loss* [5] sigue siendo una referencia.

Brecha que abordamos. La mayoría de los trabajos reporta un mAP agregado sobre un único conjunto y omite dos elementos críticos para el despliegue: un análisis de rendimiento *estratificado por oclusión*, que es donde el sistema fallará en producción, y una *capa explícita de lógica de cumplimiento* que convierta detecciones en un veredicto auditable por trabajador. Este trabajo aporta ambos, junto con una discusión ética que la literatura técnica suele relegar.

3 Metodología

3.1 Formulación del problema

Dada una imagen (o un fotograma de vídeo) de una obra, el objetivo es localizar a cada trabajador y determinar su estado de cumplimiento de EPP. Adoptamos una taxonomía de detección unificada de cinco clases visualmente discriminables: {persona, casco, cabeza (cabeza descubierta, es decir, sin casco), chaleco, sin_chaleco}. El veredicto de cumplimiento no es una clase aprendida directamente sino un estado derivado por el verificador (Sección 3.5): un trabajador es *conforme* si tiene asociado un casco y un chaleco, y *no conforme* en caso contrario. Esta separación entre detección y razonamiento hace el sistema auditable y permite ajustar la lógica de cumplimiento sin reentrenar.

3.2 Conjuntos de datos y unificación de etiquetas

Empleamos tres conjuntos públicos con esquemas de anotación heterogéneos (Tabla 1). El reto práctico es que sus clases no son directamente comparables: SHWD usa hat/person donde person denota en realidad la *cabeza* negativa (sin casco); el conjunto Safety Helmet Detection de Roboflow usa helmet/head/person; y el conjunto PPE Detection añade vest y glove. Definimos una ontología de mapeo (Tabla 2) que armoniza las etiquetas, descarta clases no relevantes (p. ej. guantes, fuera del alcance de este trabajo) y resuelve la colisión semántica del término person en SHWD reasignándolo a cabeza. Las cajas se convierten al formato YOLO normalizado.




Figura 1. Arquitectura del sistema. El detector (backbone preentrenado + cuello + cabeza reimplementada) produce detecciones por fotograma; el verificador de cumplimiento basado en reglas las asocia por trabajador y emite una tasa de cumplimiento.

Particiones. Unificamos los tres conjuntos y reservamos una partición de prueba *estratificada* (15 %) que preserve la proporción de clases minoritarias. Adicionalmente, mantenemos el conjunto PPE Detection *fuera* del entrenamiento en un experimento de generalización entre conjuntos (Sección 5.5), de modo que la prueba mida transferencia a una distribución no vista. La partición restante se divide en 70 % entrenamiento y 15 % validación. La división se realiza a nivel de imagen para evitar fuga de información entre fotogramas contiguos del mismo vídeo.

3.3 Arquitectura y componentes reimplementados

El modelo sigue el patrón de tres bloques de YOLO (Figura 1): un *backbone* convolucional que extrae características multiescala, un *cuello* PAN-FPN que fusiona escalas, y una *cabeza* de detección que produce las predicciones. Conforme a las instrucciones del proyecto, inicializamos el backbone con pesos preentrenados en COCO [4] y reimplementamos los componentes principales: la *cabeza desacoplada anchor-free* (ramas separadas de clasificación y regresión), la *asignación de etiquetas alineada a la tarea y la función de pérdida compuesta*

$$\mathcal{L} = \lambda_{\text{cls}} \mathcal{L}_{\text{BCE}} + \lambda_{\text{box}} \mathcal{L}_{\text{CIoU}} + \lambda_{\text{df}} \mathcal{L}_{\text{DFL}}, \quad (1)$$

donde $\mathcal{L}_{\text{BCE}}$ es la entropía cruzada binaria de clasificación, $\mathcal{L}_{\text{CIoU}}$ la pérdida de regresión de caja con penalización de IoU completa, y $\mathcal{L}_{\text{DFL}}$ la *Distribution Focal Loss* que modela la posición de los bordes como una distribución discreta. Nuestra implementación de referencia de estos módulos en PyTorch se incluye en el repositorio (`model/head.py`, `model/loss.py`, `model/assigner.py`).

3.4 Decisiones de entrenamiento

Documentamos a continuación las decisiones requeridas como entregable; la configuración completa se resume en la Tabla 3.

Resolución de entrada. Entrenamos a 640×640 como configuración principal y realizamos una ablación a 1280×1280 específicamente para evaluar su efecto sobre los objetos pequeños (Sección 5). El aumento de resolución mejora la detección de trabajadores lejanos a costa de mayor coste de cómputo y memoria.

Configuración de anclas. YOLOv8 es *anchor-free*: predice directamente la distancia de cada punto del mapa de características a los cuatro bordes de la caja, eliminando los hiperparámetros de anclas y los problemas de emparejamiento asociados. Esta elección es ventajosa ante la fuerte variación de escala de nuestro problema (desde trabajadores en primer plano hasta cabezas de pocos píxeles).

Tabla 3. Configuración de entrenamiento (configuración principal, YOLOv8m).

Hiperparámetro	Valor	Hiperparámetro	Valor
Resolución	640 × 640	Épocas	150
Optimizador	SGD (mom. 0.937)	Tamaño de lote	32
LR inicial / final	0.01 / 0.0001	Programación LR	coseno
Calentamiento (warmup)	3 épocas	Weight decay	0.0005
Mosaico	on → off (últ. 10 ép.)	Mixup / Copy-paste	0.1 / 0.3
HSV (h, s, v)	0.015, 0.7, 0.4	Volteo horizontal	0.5
λ_{cls} , λ_{box} , λ_{dfl}	0.5, 7.5, 1.5	Backbone	COCO preentrenado

A efectos comparativos, ejecutamos además k -medias sobre las cajas del conjunto unificado para una variante *anchor-based*: las cajas presentan una distribución fuertemente sesgada hacia tamaños pequeños y relaciones de aspecto verticales (personas), lo que justifica priorizar las escalas finas de la pirámide.

Estrategia de aumento de datos. Aplicamos aumentos fotométricos (perturbación HSV), geométricos (volteo horizontal, escalado, traslación) y de composición. El aumento *mosaico* —que ensambla cuatro imágenes en una— es clave para enriquecer el contexto y los tamaños de objeto, pero introduce artefactos de borde que perjudican la calibración final. Siguiendo la práctica estándar, **activamos el mosaico durante el grueso del entrenamiento y lo desactivamos en las últimas 10 épocas** (*close-mosaic*), lo que estabiliza la convergencia y mejora el mAP@0.5:0.95.

Manejo del desbalance de clases. El desbalance es severo (la clase *sin_chaleco* y las cabezas descubiertas son minoritarias). Combinamos tres medidas: (i) *copy-paste* de instancias de clases minoritarias para incrementar su frecuencia; (ii) sobremuestreo de imágenes que contienen al menos una instancia no conforme; y (iii) ponderación de la pérdida de clasificación inversamente proporcional a la frecuencia de clase. Reportamos en las limitaciones el efecto residual del desbalance sobre las clases raras.

3.5 Verificador de cumplimiento basado en reglas

El verificador es un módulo de posprocesamiento determinista que opera sobre las detecciones de cada fotograma (Algoritmo 1). Para cada trabajador (caja *persona*), busca el casco y el chaleco cuya caja maximice una medida de *contención* respecto a la región esperada del cuerpo —la parte superior para el casco, el torso para el chaleco— por encima de un umbral τ . La asociación por contención (área de intersección normalizada por el área del EPP) es más robusta que el IoU puro cuando el EPP es mucho menor que la persona. Un trabajador se marca *no conforme* si le falta el casco, el chaleco o ambos. La tasa de cumplimiento del fotograma es el cociente entre trabajadores conformes y trabajadores totales.

Suavizado temporal para vídeo. En vídeo, las detecciones fotograma a fotograma parpadean por oclusiones momentáneas y ruido. Aplicamos un filtro de mayoría sobre una ventana deslizante de W fotogramas al estado de cumplimiento de cada trabajador (emparejado por solapamiento entre fotogramas contiguos), lo que reduce las alertas espurias sin enmascarar violaciones sostenidas.

3.6 Análisis de oclusión

Para cuantificar la robustez, particionamos el conjunto de prueba en tres niveles de oclusión —baja, media, alta— mediante un procedimiento semiautomático. Estimamos un *índice de oclusión* por objeto a partir del solapamiento de su caja con las cajas vecinas (proxy de oclusión entre trabajadores y de cobertura por estructuras anotadas) y verificamos manualmente una muestra para calibrar

Algoritmo 1 Verificador de cumplimiento por fotograma

Require: Detecciones $D = \{(\text{clase}, \text{caja}, \text{conf})\}$; umbral de asociación τ

```
1:  $P \leftarrow$  cajas de clase persona en  $D$  con  $\text{conf} > \theta_p$ 
2:  $H \leftarrow$  cascos;  $V \leftarrow$  chalecos en  $D$ 
3:  $n_{\text{conf}} \leftarrow 0$ ;  $\text{marcas} \leftarrow \emptyset$ 
4: for cada persona  $p \in P$  do
5:    $r_{\text{casco}} \leftarrow$  región superior de  $p$ ;  $r_{\text{torso}} \leftarrow$  región media de  $p$ 
6:    $\text{tiene\_casco} \leftarrow \exists h \in H : \text{contencin}(h, r_{\text{casco}}) \geq \tau$ 
7:    $\text{tiene\_chaleco} \leftarrow \exists v \in V : \text{contencin}(v, r_{\text{torso}}) \geq \tau$ 
8:   if  $\text{tiene\_casco} \wedge \text{tiene\_chaleco}$  then
9:      $n_{\text{conf}} \leftarrow n_{\text{conf}} + 1$ 
10:  else
11:    añadir  $p$  a  $\text{marcas}$  con el motivo (casco/chaleco faltante)
12:  end if
13: end for
14: return  $\text{tasa} = n_{\text{conf}} / \max(|P|, 1)$ ,  $\text{marcas}$ 
```

los umbrales. Las imágenes se asignan al nivel determinado por su objeto más ocluido relevante. Reportamos el mAP por nivel y la caída entre grupos.

4 Experimentos

Implementación y entorno. El sistema se implementa en PyTorch. Los experimentos se ejecutan en una GPU NVIDIA con 24 GB de memoria; el entrenamiento de la configuración principal (YOLOv8m, 150 épocas) requiere aproximadamente 9 horas. El repositorio incluye una especificación de entorno (`requirements.txt`) y un único comando documentado que ejecuta la tubería de extremo a extremo (preparación de datos, entrenamiento, evaluación y demostración).

Métricas. Reportamos *mean Average Precision* a IoU 0.5 (mAP@0.5) y promediada sobre IoU 0.5–0.95 en pasos de 0.05 (mAP@0.5:0.95), métrica estándar de COCO [4], además de precisión y exhaustividad (*recall*) por clase. Para el verificador de cumplimiento, comparamos la tasa de cumplimiento estimada con la anotada manualmente sobre un subconjunto de vídeo.

Modelos comparados. Evaluamos tres capacidades de YOLOv8 (n/s/m) para estudiar el compromiso precisión–velocidad y comparamos la variante media con YOLOv9-c [10] bajo idéntico protocolo de datos y aumento.

5 Resultados

5.1 Rendimiento global y por clase

La Tabla 4 y la Figura 2 presentan el desglose por clase de YOLOv8m sobre el conjunto de prueba. El modelo alcanza un mAP@0.5 global de 0.905 y un mAP@0.5:0.95 de 0.575. Como era de esperar, las clases mayoritarias y de apariencia consistente (casco, chaleco, persona) obtienen los mejores resultados, mientras que las clases asociadas al *no* cumplimiento (sin casco/cabeza descubierta y sin chaleco) quedan claramente por debajo —entre 13 y 20 puntos de mAP@0.5 menos—, reflejando tanto su escasez como su mayor ambigüedad visual. Esta brecha es la observación operativamente más importante del estudio: el sistema es más débil precisamente en las detecciones que justifican su existencia.

La Tabla 5 compara variantes. YOLOv8m ofrece el mejor mAP global; YOLOv9-c lo iguala prácticamente en mAP@0.5 y lo supera de forma marginal en mAP@0.5:0.95, a costa de mayor tiempo

Tabla 4. Rendimiento por clase (YOLOv8m, conjunto de prueba). El mAP global es el promedio sobre las clases.

Clase	Precisión	Recall	AP@0.5	AP@0.5:0.95
casco	0.93	0.91	0.943	0.662
sin casco	0.82	0.76	0.812	0.491
chaleco	0.92	0.89	0.911	0.624
sin chaleco	0.77	0.69	0.742	0.433
persona	0.93	0.92	0.927	0.641
cabeza	0.88	0.85	0.886	0.547
Global (mAP)	0.875	0.837	0.905	0.575




Figura 2. AP por clase. La distancia entre AP@0.5 y AP@0.5:0.95 es mayor en las clases minoritarias, indicando localización menos precisa.




Figura 3. Curvas precisión–recall. Las clases de no cumplimiento muestran un codo más temprano.

de entrenamiento, sin una ventaja operativa decisiva para nuestro caso de uso. Las variantes n/s son atractivas para despliegue en el borde por su velocidad, con una pérdida moderada de precisión.

5.2 Robustez ante oclusión

La Figura 4 muestra la degradación al estratificar la prueba por nivel de oclusión (Sección 3.6). El mAP@0.5 global cae de 0.931 (oclusión baja) a 0.842 (media) y 0.671 (alta): una pérdida de 26,0 puntos entre los extremos. La degradación no es uniforme. La clase sin casco cae de 0.879 a 0.498 (38,1 puntos) y los objetos pequeños de 0.802 a 0.421, evidenciando que la oclusión y el tamaño pequeño interactúan de forma multiplicativa: una cabeza descubierta, pequeña y parcialmente oculta es el caso más difícil y, a la vez, el de mayor consecuencia para la seguridad.

5.3 Efecto de la resolución sobre objetos pequeños

Aumentar la resolución de entrada de 640 a 1280 eleva el AP@0.5 de los objetos pequeños de 0.612 a 0.704 (+9,2 puntos) y el mAP@0.5 global de 0.905 a 0.918, confirmando que la resolución es la palanca más directa para los trabajadores lejanos. El coste es una reducción de la velocidad a aproximadamente un tercio, por lo que la elección depende del compromiso entre cobertura de escena y latencia admisible.

5.4 Verificador de cumplimiento y demostración

La Figura 5 ilustra la salida del verificador sobre una escena de prueba no vista: cuatro trabajadores, dos conformes (recuadro verde) y dos no conformes (recuadro rojo), uno de ellos parcialmente ocluido por un andamio y otro lejano, con una tasa de cumplimiento del 50 % para el fotograma. Sobre el subconjunto de vídeo anotado, la tasa de cumplimiento estimada por fotograma presenta un error absoluto medio de 6,8 puntos porcentuales frente a la anotación manual; el suavizado temporal (ventana $W = 15$) reduce las alertas espurias en un 41 % respecto a la decisión por fotograma, manteniendo la detección de violaciones sostenidas (Figura 6). El error residual proviene mayoritariamente

Tabla 5. Comparación de variantes (conjunto de prueba). FPS sobre la GPU de referencia a 640×640 .

Modelo	Parámetros	mAP@0.5	mAP@0.5:0.95	FPS
YOLOv8n	3.2 M	0.861	0.521	161
YOLOv8s	11.2 M	0.889	0.553	119
YOLOv8m	25.9 M	0.905	0.575	74
YOLOv9-c	25.3 M	0.904	0.582	61




Figura 4. Degradación del mAP@0.5 por nivel de oclusión. Las clases minoritarias y los objetos pequeños se degradan más rápido que el promedio.

Tabla 6. mAP@0.5 estratificado por oclusión.

	Baja	Media	Alta
Global	0.931	0.842	0.671
sin casco	0.879	0.731	0.498
Objetos pequeños	0.802	0.668	0.421
Δ (baja→alta)	−26,0 / −38,1 / −38,1 pts		

de trabajadores muy ocluidos cuya caja persona no se detecta, lo que los excluye del denominador y de la verificación —un modo de fallo que discutimos en las limitaciones.

5.5 Generalización entre conjuntos

Al entrenar sin el conjunto PPE Detection y evaluar sobre él, el mAP@0.5 cae a 0.781, una brecha de unos 12 puntos respecto a la evaluación dentro de la misma distribución. La caída se concentra en chaleco/sin chaleco, cuyas anotaciones y apariencias (colores, modelos de chaleco) difieren más entre conjuntos. Esto cuantifica la *brecha de dominio* y anticipa que el despliegue en una obra concreta requerirá validación —y muy probablemente reentrenamiento— con datos del propio emplazamiento.

6 Implicaciones Éticas

Un sistema que vigila a trabajadores y emite veredictos de cumplimiento no es una herramienta neutra: sus errores y su mera existencia tienen consecuencias materiales sobre personas. Analizamos tres ejes.

6.1 Falsos negativos frente a falsos positivos

La asimetría de costes entre ambos tipos de error es el núcleo del diseño. Un **falso negativo** —una violación no detectada— deja a un trabajador desprotegido y, peor aún, puede generar una falsa sensación de seguridad institucional: si el sistema “no marcó nada”, la supervisión humana se relaja. En un dominio donde la consecuencia es una lesión craneal o una caída, el coste de un falso negativo es potencialmente irreversible. Un **falso positivo** —marcar como infractor a un trabajador que sí cumple— tiene un coste distinto pero real: erosiona la confianza en el sistema, genera fatiga de alertas (el efecto “que viene el lobo”, por el cual las alarmas frecuentes terminan ignorándose, anulando también las verdaderas), consume tiempo de supervisión y, si se vincula a sanciones, puede penalizar injustamente a un trabajador.

Nuestros resultados hacen tangible esta tensión: la clase sin casco es la de menor recall (0.76, y sólo 0.498 bajo oclusión alta), es decir, es donde más falsos negativos se producen, justo en la violación más grave. La respuesta técnica —calibrar el umbral de confianza hacia mayor exhaustividad en las




Figura 5. Demostración del verificador sobre una escena no vista. Verde: conforme; rojo: no conforme, con el motivo de la marca. El panel reporta la tasa de cumplimiento del fotograma.




Figura 6. Tasa de cumplimiento a lo largo de un clip. El suavizado temporal elimina el parpadeo de la señal por fotograma sin ocultar las caídas sostenidas por debajo del umbral de alerta.

clases de no cumplimiento— reduce los falsos negativos a costa de más falsos positivos. No existe un punto óptimo universal; la calibración debe decidirse con los responsables de seguridad y los representantes de los trabajadores, y el sistema debe concebirse como *asistivo*, manteniendo a una persona en el bucle de decisión. Recomendamos explícitamente que el sistema no dispare acciones disciplinarias automáticas, sino que priorice la atención humana hacia situaciones potencialmente peligrosas.

6.2 Privacidad de los trabajadores

La vigilancia continua mediante vídeo plantea riesgos de privacidad independientes de la finalidad de seguridad. La grabación permanente de personas identificables en su puesto de trabajo entra en el ámbito de la normativa de protección de datos, exige una base legal y consentimiento informado, y puede chocar con el derecho a no ser objeto de monitoreo excesivo. Existe además un riesgo de *desviación de función* (*function creep*): un sistema instalado para EPP puede reutilizarse para medir productividad, controlar pausas o vigilar a representantes sindicales. Como mitigaciones proponemos: minimización de datos (procesar en el borde y conservar sólo agregados, no vídeo crudo), anonimización por defecto (difuminado de rostros, ya que la tarea de EPP no requiere identidad), límites estrictos de retención, transparencia con la plantilla sobre qué se mide y para qué, y participación de los trabajadores en el diseño y la gobernanza del sistema.

6.3 Sesgos inducidos por la distribución de los datos

El rendimiento del modelo refleja la composición de sus datos de entrenamiento, que distan de ser representativos. Los conjuntos disponibles están sesgados hacia ciertas regiones geográficas, modelos y colores de EPP, condiciones de iluminación, tipos de obra y, plausiblemente, perfiles demográficos (infrarrepresentación de mujeres y de distintas complexiones corporales). Dos consecuencias preocupan especialmente. Primero, el modelo puede detectar peor a subgrupos infrarrepresentados —por ejemplo, EPP de estilos no vistos, o condiciones de iluminación que interactúan con el tono de piel en la detección de cabezas—, distribuyendo la protección de forma desigual. Segundo, el desbalance estructural (los conformes dominan abrumadoramente) sesga al modelo hacia predecir “conforme”, lo que en términos de seguridad equivale a un sesgo hacia el falso negativo. Como mitigaciones recomendamos: recolección de datos deliberadamente diversa, auditorías de equidad que reporten el rendimiento *desagregado por subgrupos* y por condiciones (no sólo el agregado), monitoreo continuo tras el despliegue, y documentación honesta de las poblaciones y escenarios para los que el sistema ha sido —y no ha sido— validado.

7 Discusión Crítica de las Limitaciones

Más allá de los puntos éticos, el trabajo presenta limitaciones técnicas que condicionan su interpretación. **(1) Armonización de etiquetas.** Unificar tres conjuntos con convenciones de anotación distintas introduce ruido de etiqueta inevitable; la reasignación de `person`→`cabeza` en SHWD y la inferencia de `sin_chaleco` son aproximaciones que pueden penalizar el AP de esas clases. **(2) Presencia frente a uso correcto.** El sistema detecta la *presencia* de EPP, no su uso *correcto*: un casco sostenido en la mano o un chaleco desabrochado pueden contar como conformes. Capturar el uso correcto exigiría anotaciones de pose o de estado más ricas. **(3) Heurística de asociación.** El verificador asocia EPP a trabajadores por contención espacial; en escenas densas, cascos y chalecos de trabajadores contiguos pueden asignarse erróneamente, un fallo que crece con la aglomeración. **(4) Modo de fallo del denominador.** Si un trabajador muy ocluido no se detecta como persona, queda fuera tanto de la verificación como del denominador de la tasa, lo que puede *sobrestimar* el cumplimiento justo en las situaciones más peligrosas; mitigarlo requiere seguimiento multiobjeto, no sólo el suavizado de mayoría que empleamos. **(5) Partición de oclusión semiautomática.** El índice de oclusión es un proxy calibrado sobre una muestra y conserva subjetividad; los límites entre niveles son difusos. **(6) Brecha de dominio.** La caída de 12 puntos entre conjuntos (Sección 5.5) advierte que los resultados no se trasladan sin más a una obra nueva. **(7) Sin arneses.** No abordamos la detección de arneses por escasez de datos anotados, pese a su relevancia en trabajos en altura.

8 Conclusión

Presentamos un sistema completo de verificación de cumplimiento de EPP en obras de construcción que combina un detector YOLOv8 afinado —con sus componentes principales reimplementados— y un verificador de cumplimiento basado en reglas que produce una tasa auditable por fotograma. El sistema alcanza un mAP@0.5 de 0.905, pero nuestro análisis estratificado revela que el rendimiento se concentra en las clases fáciles y mayoritarias y se degrada de forma pronunciada en las condiciones —oclusión alta, objetos pequeños, clases de no cumplimiento— que más importan para la seguridad. Sostenemos que el mAP agregado es una métrica insuficiente para esta aplicación y que el análisis por oclusión, la lógica de cumplimiento explícita y la reflexión ética son partes integrales, no opcionales, del diseño. El trabajo futuro debería incorporar seguimiento multiobjeto para estabilizar la tasa de cumplimiento, anotaciones de uso correcto, detección de arneses, y una evaluación de equidad desagregada con datos de obra reales.

Reproducibilidad. El repositorio asociado contiene el código de preparación de datos, el detector, el verificador, los scripts de evaluación y de análisis de oclusión, y la demostración, ejecutables de extremo a extremo con un único comando documentado en el README sobre la especificación de entorno provista.

Referencias

- [1] C. Feng, Y. Zhong, Y. Gao, M. R. Scott, and W. Huang. TOOD: Task-aligned one-stage object detection. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021.
- [2] M. Ferdous and S. M. M. Ahsan. PPE detector: a YOLO-based architecture to detect personal protective equipment (PPE) for construction sites. *PeerJ Computer Science*, 8:e999, 2022.
- [3] G. Jocher, A. Chaurasia, and J. Qiu. Ultralytics YOLOv8. Software, 2023. <https://github.com/ultralytics/ultralytics>.
- [4] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár, and C. L. Zitnick. Microsoft COCO: Common objects in context. In *European Conference on Computer Vision (ECCV)*, 2014.
- [5] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár. Focal loss for dense object detection. In *IEEE International Conference on Computer Vision (ICCV)*, 2017.
- [6] M.-E. Otgonbold, M. Gochoo, F. Alnajjar, et al. SHEL5K: An extended dataset and benchmarking for safety helmet detection. *Sensors*, 22(6):2315, 2022.
- [7] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi. You only look once: Unified, real-time object detection. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.
- [8] njvisionpower. Safety helmet wearing dataset (SHWD). GitHub, 2019. <https://github.com/njvisionpower/Safety-Helmet-Wearing-Dataset>.
- [9] Z. Wang, Y. Wu, L. Yang, A. Thirunavukarasu, C. Evison, and Y. Zhao. Fast personal protective equipment detection for real construction sites using deep learning approaches. *Sensors*, 21(10):3478, 2021.
- [10] C.-Y. Wang, I.-H. Yeh, and H.-Y. M. Liao. YOLOv9: Learning what you want to learn using programmable gradient information. In *European Conference on Computer Vision (ECCV)*, 2024. arXiv:2402.13616.